

Trabajo práctico 3

[illegible]

3 de septiembre de 2021

Lukas Nahuel De Angelis Riva
103784

Mateo Capón Blanquer
104258



Enunciado

Como el análisis espectrométrico es más barato que el análisis químico, se procuró calibrar el primero para que reemplace al segundo. Con este objetivo se tomó una muestra de 180 vasijas, a las que se realizó una espectrometría de rayos X sobre 1920 frecuencias, y también un análisis de laboratorio para determinar el contenido de 13 compuestos químicos, a saber:

Los siguientes datos corresponden a un trabajo para determinar la composición de un conjunto de vasijas de vidrio de un yacimiento arqueológico. Cada fila del archivo Vessel X es el espectro de una vasija, limitado a las frecuencias 100 a 400, pues las demás tienen valores casi nulos. Cada fila del archivo Vessel Y tiene los contenidos de los 13 compuestos en esa vasija. Vamos a comparar distintos métodos. Ahora se trata de predecir el compuesto 1 (óxido de sodio). Utilizando todo lo aprendido, encontrar un modelo para poder predecir.

Análisis exploratorio

A continuación se presentará la estructura de los datos a analizar.

Variables predictoras


Estructura

	f100	f101	f102	...	f399	f400
1	140.4	139.4	120.00	...	118.6	101.6
180	288.0	279.4	274.20	...	129.0	117.8

Siendo cada entrada de la tabla el espectro de una vasija frente a las frecuencias que se encuentran encolumnadas. Estas frecuencias toman valores entre 100 y 400; ya que, según el enunciado, las demás frecuencias poseen una respuesta cercana a cero.

Distribución

Para analizar la distribución de las variables predictoras realizaremos un gráfico que muestre la respuesta de las vasijas frente a las frecuencias. Para ello graficaremos una curva que simboliza la respuesta mediana de todas las vasijas frente a una frecuencia y, además, un intervalo intercuantílico del 95 % para esa misma respuesta. Por ejemplo, para la respuesta frente a la frecuencia f_{100} tendremos $Respuesta_{f_{100}} = median(f_{100})$. Además se optó por una escala logarítmica para la respuesta.



Como primera observación podemos notar que las frecuencias parecen tener un sentido de orden y continuidad, es decir, la respuesta entre frecuencias cercanas parece ser de la misma magnitud, esto nos da a entender que la respuesta no varía significativamente con cambios pequeños en la frecuencia, es decir: $Respuesta_{f_i} \approx Respuesta_{f_{i \pm 1}}$. Por lo que esto nos avisa de una posible correlación entre las frecuencias vecinas.



Luego podemos ver que para algunas frecuencias cercanas a 165 se alcanza un máximo global para la respuesta, mientras que para otras frecuencias como las cercanas a 320 o 355 se alcanzan máximos locales considerablemente grandes. Para todas las demás frecuencias la respuesta parece haber sido similar, habiendo casos particulares como para las frecuencias cercanas a 250 que alcanza otro pico, pero de menor magnitud.

Además, podemos notar que los intervalos intercuantílicos no parecen ser muy anchos (salvo algunos casos particulares), por lo que creemos que todas las vasijas halladas en el yacimiento arqueológico se comportan de forma similar.

Por último, realizaremos un test sobre normalidad para cada frecuencia con el objetivo de asegurarnos si podemos o no suponer una distribución normal multivariada para las frecuencias. Utilizamos dos tests diferentes, estos son:

- Lilliefors test¹
- Shapiro–Wilk test²

Decidimos utilizar estos dos tests para contrastar los resultados y tener mayor seguridad.³



¹<https://search.r-project.org/CRAN/refmans/nortest/html/lillie.test.html>

²<https://www.rdocumentation.org/packages/stats/versions/3.6.2/topics/shapiro.test>


³https://www.researchgate.net/publication/267205556_Power_Comparisons_of_Shapiro-Wilk_Kolmogorov-Smirnov_Lilliefors_and_Anderson-Darling_Tests

Ambos tests nos brindan la misma información, las observaciones no siguen una distribución normal multivariada.

Correlación

Como observamos anteriormente, es posible que las frecuencias estén correlacionadas dentro de las vecindades, como así podrían incluso estar correlacionadas por fuera de las vecindades. Para ello realizamos un gráfico de Heatmap en el que veremos sobre el continuo de las frecuencias la estimación $\hat{C}_{corr}$ de la correlación entre ellas.

HeatMap de la matriz de correlaciones para las frecuencias



Como primera observación podemos ver que efectivamente las respuestas a determinadas frecuencias se comportan de manera similar para frecuencias parecidas. Esto podemos observarlo mediante la forma que adoptan las correlaciones dentro de $\hat{C}_{corr}$, las frecuencias vecinas se correlacionan similarmente con otras vecindades formando así los rectángulos de color que podemos ver en el gráfico.

Además, podemos ver que efectivamente las correlaciones en la diagonal de la matriz son cercanas a 1, esto se corresponde perfectamente con lo que habíamos observado. A su vez, por fuera de la diagonal de la matriz hay correlaciones altas (sean positivas o negativas) por lo que esto se traducirá en un problema al utilizar modelos que requieran datos descorrelacionados para funcionar correctamente. En consecuencia, será necesario realizar una selección previa de variables.

Variable objetivo


Estructura

	Y
1	13.904
180	13.890

Cada entrada corresponde al contenido del compuesto Y (Óxido de sodio [Na₂O]) en la vasija enumerada por la fila.

Distribución

A continuación el gráfico mostrará la estimación de la densidad de la variable a predecir.



Podemos ver que los datos tienen una distribución peculiar, siendo que posee dos picos, uno mucho más grande que el otro para los valores 15 y 5 respectivamente. Además podemos observar que los puntos que conforman el pico secundario arrastran el intervalo intercuartílico así como la media muestral hacia valores intermedios con una menor densidad de puntos, esto provoca que, por ejemplo tomando la media muestral como predicción de la variable objetivo, resulte en una predicción pobre.

Algunos estadísticos de la muestra:


Min	1stQ	Median	Mean	3thQ	Max	Var
0.986	11.989	14.177	12.550	15.446	17.586	18.793

Estimación de la correlación entre las variables predictoras y objetivo

Para ello realizamos un gráfico donde mostramos para cada frecuencia (es decir las variables predictoras) tanto diferentes respuestas que resultan interesantes (en el eje vertical derecho) como

la estimación de la correlación con la variable objetivo (eje vertical izquierdo).

Correlación del espectro de cada frecuencia con el contenido de Óxido de Sodio en las vasijas



A simple vista podemos observar que para frecuencias vecinas la correlación con la variable objetivo varía poco, exceptuando en los puntos de cambio de signo donde se produce un salto abrupto de la correlación con la variable objetivo.

Cabe destacar también el comportamiento del espectro de las vasijas frente a los cambios de signo en la correlación con la variable objetivo. El espectro de las vasijas cuyo contenido de óxido de sodio es menor (la curva azul) y el espectro de las vasijas cuyo contenido de óxido de sodio es mayor (la curva roja) fluctuarán sus posiciones relativas dependiendo de la correlación con la variable objetivo.

Por ejemplo, para el pico principal del espectro (para las frecuencias cercanas a 160) se tiene una correlación positiva, eso quiere decir que, en promedio, la respuesta debería crecer a medida que crece el contenido de óxido de sodio en la vasija, y eso se puede notar observando el orden de los espectros pues la roja se encuentra por encima de la negra y a su vez ambas por encima de la azul. De la misma manera se puede observar que cuando la correlación resulta negativa (por ejemplo para los picos secundarios, es decir frecuencias cercanas a 350), la curva azul se encuentra por encima de la curva negra y a su vez ambas por encima de la curva roja, dando a entender que a mayor contenido de óxido de sodio en las vasijas, más baja será su respuesta a la frecuencia.

Por último queremos destacar que ninguna variable objetivo tiene una correlación alta (es decir de valor absoluto cercano a 1) como así también son pocas las variables cuya correlación es baja (es decir cercana a 0). Por lo que a priori no podemos descartar variables a partir del análisis exploratorio.

Esquema de trabajo

División en train y test

Una vez realizado el análisis exploratorio sobre el comportamiento de las variables, procedemos a la etapa de generación de modelos predictivos. En función de tener un esquema trabajo organizado de forma tal que, una vez finalizada la etapa de creación y evaluación de modelos, se pueda dar una estimación más precisa del error de predicción de los modelos realizados, decidimos partir los datos en “train” y “test”. Los datos separados en “test” no los usamos sino hasta el final del trabajo práctico y con el único objetivo de decidir si nuestro modelo predice con la precisión requerida. Mientras que los datos separados en “train” serán utilizados para entrenar los modelos,

y sobre los que a su vez se realizarán técnicas de validación cruzada (Kfold para la búsqueda de hiper-parámetros y LOOCV para la estimación insesgada del error).

Decidimos que la cantidad de datos en test sea de 20, es decir tan solo un 11.1 % de los datos.

Métricas para la evaluación y selección de modelos

Previo a comenzar la generación de modelos, decidimos utilizar las siguientes métricas para la evaluación.:

1. Utilizamos el error cuadrático medio para la búsqueda de hiper-parámetros.
2. Utilizamos $LOOCVR_{adj}^2$ para la elección de los modelos según su preprocesamiento.

Un factor que debemos tener siempre en cuenta a la hora de analizar la bondad de los modelos es el trade-off que existe entre el sesgo y la varianza. Por más de que utilicemos Cross Validation para la selección de hiper-parámetros y variables o tipos de preprocesamientos, se evalúa todo sobre el set de entrenamiento. Por lo tanto, es posible que todas las métricas que se calculen sobre el mismo no sean muy representativas a causa del sesgo (sobreajuste) que produce la selección, inclusive la selección de variables.

Creación y evaluación de modelos

Sin selección de variables

En la presente sección se crearán y se evaluarán los siguientes modelos.

- Regresión lineal (regularizada según Elastic-Net)
- Árbol de regresión
- KNN para regresión
- Regresión no paramétrica

El hecho de no realizar ningún tipo selección de variables, nos permite tener valores de referencia sobre los resultados de los distintos modelos. De este modo, podremos comparar los presentes resultados con los obtenidos al realizar una selección previa de las variables y concluir si la selección fue buena o no.

Regresión lineal regularizada

La regresión lineal regularizada la consideramos con los siguientes hiper-parámetros, los cuales iteramos sobre una grilla.

- **Alpha** (α): coeficiente de Lasso (si $\alpha = 1$ se aplica únicamente Lasso, si $\alpha = 0$ únicamente Ridge). Iteramos los siguientes valores $seq(0, 1, 0,05)$.
- **Lambda** (λ): coeficiente de regularización, mientras más grande sea su valor mayor será la fuerza de regularización (más se penaliza a los coeficientes altos). Iteramos los siguientes valores $logspace(-10, 3, 50)$

Además, al haber penalización sobre los β_i , tuvimos que escalar los datos. En este sentido probamos tanto con un escalador de los datos a valores entre 0 y 1, como también normalizar los datos, para que tengan media 0 y varianza 1.


A continuación mostramos el mejor resultado obtenido utilizando Cross-Validation con $k = 5$.

Alpha	0.15
Lambda	0.057
Escalador	MinMaxScaler

Utilizando estos hiper-parámetros y el dicho escalador, se obtiene por LOOCV la estimación insesgada del ECM:

$$\widehat{ECM} = \frac{\sum_{i \text{ in train}} r_{-i}^2}{\#train} = \frac{\sum_{i \text{ in train}} (y_i - \hat{y}_{-i})^2}{\#train} = 0,8650$$

A continuación mostramos los $\hat{\beta}$ estimados en la generación del modelo.



El modelo decidió descartar 175 variables (en color violeta). De este modo, el R_{adj}^2 se reduce, al disminuirse la cantidad de variables, su valor será el siguiente, siendo $p = 301 - 175 = 126$ y $n = 160$:

$$R_{adj}^2 = 1 - \frac{(n-1) \cdot \|Y - \hat{Y}\|^2}{(n-p) \cdot \|Y - \bar{Y}\|^2} = 0,7684$$

Resumen

	Tipo	Preprocesamiento	$\widehat{ECM}$	R_{adj}^2	p
M1	RLM	MinMaxScaler	0,8650	0,7684	126

Árbol decisión

El siguiente modelo que entrenamos fue el árbol de decisión. Para el mismo, iteramos sobre los siguientes hiper-parámetros.

- **minsplits**: mínima cantidad necesaria de observaciones en un nodo para que se permita separar el mismo.
Iteramos los valores 2; 5; 10; 15; 20; 25.
- **maxdepth**: máxima profundidad que un nodo hoja puede tener.
Iteramos los siguientes valores: 4; 5; 6; 7; 8.

- **CP**: parámetro de complejidad, su valor determina el factor de falta de ajuste necesario a disminuir antes de realizar una partición.
Iteramos los siguientes valores: 0,0005; 0,001; 0,005; 0,01; 0,015; 0,025.

Vale aclarar que tanto para el árbol de decisión, como para los métodos basados en árboles en general, no se escalan los datos.


A continuación mostramos el mejor resultado obtenido utilizando Kfold Cross-Validation con $k = 10$.

minsplits	2
maxdepth	4
CP	0.01

Utilizando estos hiper-parámetros, calculamos el error cuadrático medio estimado por LOOCV.
 $\widehat{ECM} = 1,6682$

A continuación mostramos el esquema general del modelo generado.

Modelo 2



El modelo utilizó únicamente $p = 3$ variables. De este modo, el R_{adj}^2 da como resultado:

$$R_{adj}^2 = 0,9033$$

Resumen

	Tipo	Preprocesamiento	$\widehat{ECM}$	R_{adj}^2	p
M2	ABR	-	1,6682	0,9033	3

Vecinos más cercanos (KNN)

Los hiper-parámetros a considerar en KNN son los siguientes:

- **K**: la cantidad de vecinos más cercanos a tener en cuenta en la predicción. Iteramos sobre los siguientes valores: 1, 2, 3, 4, 5, 6.
- **Métrica de distancia**: la métrica con la que se calcula la distancia entre dos puntos. Las posibles normas sobre las que iteramos son la L1, y la L2.
- **Pesos**: factor que pondera la regresión. Los pesos que iteramos fueron:
 - Uniforme: asigna el mismo peso para todas las instancias.
 - Distancia: asigna un peso inversamente proporcional según la distancia.

Además se deben escalar los datos en KNN, de forma tal que no haya variables que determinen por sí solas el valor de la distancia al tener un rango más grande que otras variables (como podrían ser los picos vistos en el análisis exploratorio). Nuevamente, con Cross Validation se eligió el escalador óptimo (siendo MinMax y StScaler los posibles)

A continuación mostramos la mejor combinación de hiper-parámetros obtenida utilizando K-fold Cross Validation con $k = 10$.

K	2
Distancia	L2
Peso	Distancia
Escalador	MinMaxScaler

Utilizando estos hiper-parámetros, calculamos el error cuadrático medio estimado por LOOCV. $\widehat{ECM} = 0,8249$

Resumen

	Tipo	Preprocesamiento	$\widehat{ECM}$	R_{adj}^2	p
M3	KNN	MinMaxScaler	0,8249	—	301

Vale remarcar que no se incluye el R_{adj}^2 , porque la cantidad de variables utilizadas por este modelo es mayor a la cantidad de observaciones.

Regresión no paramétrica

Decidimos utilizar el modelo no paramétrico de Nadaraya-Watson multivariado con p variables. Se predice mediante la siguiente función.

$$\widehat{m_h(x)} = \frac{\sum_{i=1}^n w_i \cdot y_i}{\sum_{i=1}^n w_i}$$

Siendo

$$w_i = K \left(\frac{D(x_0, x_i)}{h} \right)$$

y D una medida de distancia.

De este modo, se ponderan todas las variables en relación a la cercanía de los puntos a la observación sobre la cual se busca predecir, es por ello que fue necesario realizar un previo escalado de los datos para no tener los problemas explicados en KNN.

Para el presente modelo, tuvimos que encontrar los mejores valores para la ventana h , sabiendo

que a menor h mayor será el overfitting; y que a mayor h mayor será el underfitting. Además, se debe encontrar un núcleo (o kernel) K óptimo y una medida de distancia para los puntos. Luego de realizar k-Fold Cross Validation con $k=10$ obtuvimos los siguientes resultados:

Ventana h	5.7517
K	Gaussian
Métrica de Distancia	L1
Escalador	MinMaxScaler

Resumen

	Tipo	Preprocesamiento	$\widehat{ECM}$	R^2_{adj}	p
M4	RNP	MinMaxScaler	1,1651	—	301

Reducción dimensional

Todos los modelos entrenados previamente tienen la característica de que no se realiza ningún tipo de selección de variables previo a entrenar. En esta sección propondremos diferentes métodos para la reducción dimensional

Reducción dimensional: por rango de frecuencias

Como hemos visto en el análisis exploratorio, las frecuencias vecinas tienden a comportarse parecido, sea en la intensidad de la respuesta del espectro, como así también en la correlación con la variable objetivo. Es por ello que propondremos en esta sección realizar la siguiente reducción dimensional.

Dado que se tienen 301 frecuencias, la transformación será la siguiente:

$$V_i^* = \frac{1}{h} \sum_{j=(i-1) \cdot h + 1}^{i \cdot h} V_j, \quad i = 1, 2, \dots, \left\lfloor \frac{p}{h} \right\rfloor$$

$$V_{\left\lfloor p/h \right\rfloor}^* = \frac{\sum_{j=\left\lfloor \frac{p}{h} \right\rfloor \cdot h}^p V_j}{p - \left\lfloor \frac{p}{h} \right\rfloor \cdot h}$$

Por ejemplo, si $h = 30$ tendremos que:


$$V_1^* = \frac{V_1 + V_2 + \dots + V_{30}}{30}$$

$$V_2^* = \frac{V_{31} + V_{32} + \dots + V_{60}}{30}$$

$$\dots$$


$$V_{11}^* = V_{301}$$

La ventana a utilizar será obtenida mediante Cross Validation así como los hiper-parámetros de los modelos a entrenar. Pero, a modo de ejemplificación, mostraremos cómo queda la matriz de correlaciones estimada para las frecuencias agrupadas en grupos de 30.



Se puede ver que, a diferencia de todas las frecuencias juntas, las variables parecen haberse descorrelacionado.

Mientras que para h pequeños, por ejemplo $h = 4$, se obtiene la siguiente matriz de correlaciones:



En la que se puede observar que la estructura general de correlaciones se mantuvo, no así la nueva cantidad de variables, esto supondrá una ventaja para los modelos que necesitan $n > p$.

Observación:

Este preprocesamiento, si bien disminuye considerablemente la cantidad de variables con las que entrenarán los modelos, no disminuye la complejidad del mismo pues, a priori, aún será necesario medir el espectro para todas las frecuencias entre 100 y 400. Es decir, no disminuye los costos de operación.


Entrenamiento

Siguiendo las metodologías aplicadas en la sección previa, entrenamos los mismos modelos, iterando también sobre la ventana.

Regresión lineal regularizada

Para este modelo, obtuvimos los siguientes resultados.

Ventana	15
Alpha	0
Lambda	1e-04
Escalador	MinMaxScaler



Es esperable que con estos parámetros no haya variables descartadas por el modelo porque solamente hay regularización Ridge (se descarta Lasso).

El $\widehat{ECM}$ por LOOCV es de 0,6782

Y R^2_{adj} no se puede calcular porque usamos la misma cantidad de frecuencias para realizar la media (es decir son 301, mayor que n).


Resumen

	Tipo	Preprocesamiento	$\widehat{ECM}$	R^2_{adj}	p
M5	RLM	MinMaxScaler + Ventana(15)	0,6782	—	301

Árbol de regresión

Para este modelo, obtuvimos los siguientes resultados:

Ventana	2
MinSplit	2
MaxDepth	4
CP	0.001



Como se puede ver en la figura, el árbol utilizó un total de 9 variables V^* , por lo que utilizó un total de 18 frecuencias para realizar la predicción.

El $\widehat{ECM}$ por LOOCV es de 1,4631

Como el árbol utilizó únicamente 18 frecuencias, es posible calcular el valor de R_{adj}^2 . Considerando entonces que $p = 18$ su valor es:

$$R_{adj}^2 = 0,9062$$

Resumen

	Tipo	Preprocesamiento	$\widehat{ECM}$	R_{adj}^2	p
M6	ABR	Ventana(2)	1,4631	0,9062	18

Vecinos más cercanos (KNN)

No entraremos en detalle de los resultados obtenidos para este modelo, pues se calculan igual que en la sección anterior y tampoco tenemos las herramientas disponibles para desplegar un gráfico sobre su predicción (debido a la alta dimensionalidad). Se obtuvieron los siguientes valores para los hiper-parámetros:

Ventana	32
K	2
Distancia	L1
Peso	Distancia
Escalador	MinMaxScaler

Resumen

	Tipo	Preprocesamiento	$\widehat{ECM}$	R_{adj}^2	p
M7	KNN	Ventana(32)	0,5966	—	301

Regresión no paramétrica

Ventana	4
Ventana h	1.6414
K	Gaussiano
Métrica de Distancia	L1
Escalador	MinMaxScaler

Resumen

	Tipo	Preprocesamiento	$\widehat{ECM}$	R_{adj}^2	p
M8	RNP	MinMaxScaler+Ventana(4)	0,6796	—	301

Reducción dimensional: PCA

Como hemos visto en el análisis exploratorio, las matriz de correlaciones estimada de las variables predictoras muestra que estas últimas en pocos casos se encuentran descorrelacionadas. Esto sumado también al hecho de que tenemos una gran cantidad de variables predictoras se convierte en el foco principal a la hora de realizar un preprocesamiento. Entonces, como es necesario reducir la dimensión y tenemos variables muy correlacionadas (al punto de que múltiples variables se comportan similar tanto entre ellas como con la variable objetivo) tenemos la necesidad de re-estructurar la información con la que trabajamos, y es aquí donde entra PCA.

En primer lugar, normalizamos las variables predictoras, luego realizamos la descomposición espectral de la estimación de la matriz de covarianzas de las variables normalizadas (de ahora en adelante $\widehat{\Sigma}$) como sigue:

Siendo $\widehat{\lambda}_1, \widehat{\lambda}_2, \dots, \widehat{\lambda}_{301}$ los autovalores de $\widehat{\Sigma}$ ordenados de mayor a menor; y sean $\widehat{\gamma}_1, \widehat{\gamma}_2, \dots, \widehat{\gamma}_{301}$ los autovectores asociados. La descomposición espectral de $\widehat{\Sigma}$ viene dada por


$$\widehat{\Gamma}^T \widehat{\Sigma} \widehat{\Gamma} = \widehat{\Lambda}$$

donde $\widehat{\Gamma} = (\widehat{\gamma}_1, \widehat{\gamma}_2, \dots, \widehat{\gamma}_{301})$ y $\widehat{\Lambda} = \text{diag}(\widehat{\lambda}_i)_{i=1}^{301}$

Ahora procedemos a calcular los autovalores de $\widehat{\Sigma}$ y sus intervalos de confianza mediante la técnica de bootstrapping.⁴


Utilizamos este método porque, tal como mencionamos en el análisis exploratorio, las variables no se distribuyen normalmente, y es por ello que descartamos que la distribución conjunta sea normal multivariada. Por lo tanto no podemos utilizar los test de inferencia para el caso normal y tuvimos que ir por un método computacional. Mostramos a continuación los intervalos de confianza obtenidos por bootstrapping para los λ_i .

⁴<https://blogs.sas.com/content/iml/2020/10/26/confidence-interval-eigenvalues.html>




Podemos notar que hasta el λ_6 no ocurre ningún tipo de superposición de los intervalos de confianza. Ya para λ_7 y λ_8 (y en adelante) los intervalos de confianza se superponen y por lo tanto no se puede asegurar que no sean iguales.


Basados en este argumento, tomaremos únicamente las primeras 6 componentes principales, que son con las cuales se cumple el supuesto del orden descendente de los λ . Además, esta elección se ve reforzada por el hecho de que las primeras 5 (y por ello 6) λ explican una varianza mayor al 90 % con una confianza del 99 %, esto se puede ver en el siguiente gráfico:



También comentar que tomando únicamente las primeras dos componentes se explica más del 60 % de la varianza (con una confianza del 99 %), y cuya proyección se ve la siguiente manera:



Queremos rescatar de este gráfico que parecen formarse pequeñas regiones respecto a la variable objetivo, esto podría ser beneficioso para modelos como KNN y regresión no paramétrica. Antes de empezar con el entrenamiento de los modelos, mostraremos a continuación tanto la distribución como las correlaciones entre las primeras 6 componentes principales.



PCA(6)

En esa sección utilizaremos las primeras 6 componentes principales, la idea será entrenar los mismos modelos que en las secciones anteriores, estos son:

- Regresión lineal
- KNN
- Árbol de regresión
- Regresión no paramétrica

Regresión lineal

Utilizando las primeras 6 componentes obtuvimos el siguiente resultado:

$$\hat{Y} = 12,6781 - 0,2024 \cdot CP_1 - 0,3190 \cdot CP_2 + 0,1684 \cdot CP_3 - 0,12 \cdot CP_4 - 0,1464 \cdot CP_5 - 0,4047 \cdot CP_6$$

Cuyo error por LOOCV es de 2,2974.

Resumen

	Tipo	Preprocesamiento	$\widehat{ECM}$	R_{adj}^2	p
M9	LM	PCA(6)	2,2974	—	301


Árbol de regresión

Los hiper-parámetros óptimos encontrados se presentan en la siguiente tabla.

MinSplit	5
MaxDepth	7
CP	5e-04

Graficamos a continuación el modelo generado con estos parámetros.

Modelo 2



Es interesante observar como, a causa de los parámetros encontrados, divide a los datos en hojas de muy pocas muestras (entre 2 y 10 muestras), a diferencia de los anteriores dos árboles de regresión generados.

Resumen

	Tipo	Preprocesamiento	$\widehat{ECM}$	R^2_{adj}	p
M10	ABR	PCA(6)	1,1637	—	301

Vecinos más cercanos KNN

K	2
Distancia	L2
Peso	Distancia
Escalador	StScaler

Resumen

	Tipo	Preprocesamiento	$\widehat{ECM}$	R_{adj}^2	p
M11	KNN	PCA(6)	0,8652	—	301

Regresión no paramétrica

Ventana h 0.1	
K	Gaussiano
Métrica de Distancia	L1
Escalador	MinMaxScaler

Resumen

	Tipo	Preprocesamiento	$\widehat{ECM}$	R_{adj}^2	p
M12	RNP	PCA(6)	0,9318	—	301

PCA(2)



Por más que ya hemos realizado las predicciones con PCA(6), que en general deberían tener mejores resultados que con PCA(2), decidimos entrenar los mismos modelos que realizamos previamente ya que, como estamos en R^2 , podremos visualizar las predicciones con gráficos, que hasta ahora no hemos podido.

Regresión lineal

La regresión lineal que se obtuvo fue la siguiente:

$$\hat{Y} = 12,6781 - 0,2024 \cdot CP_1 - 0,3190 \cdot CP_2$$


En los siguientes gráficos podremos ver la regresión obtenida:




El error por LOOCV fue de 4.7719, por lo que es evidente que no se trata de un buen modelo a utilizar, sin embargo, se puede evidenciar al menos algunos de los problemas que tiene la regresión lineal para 6 dimensiones. Como se puede ver en el gráfico, parecen existir dos grandes clusters para valores de Y altos, así como también existe un cluster más pequeño para los valores de Y bajos, esto provoca (al menos en R^2 , pero creemos que también en R^6) que no haya una relación lineal entre las variables, generando así un modelo bastante pobre.

Árbol de decisión

De forma similar, en este caso queremos ver cómo el árbol de regresión entrenado está partiendo R^2 para realizar la predicción. El árbol entrenado fue el siguiente:




Y su error mediante LOOCV dio 5,2005. Nuevamente se puede ver que el modelo es bastante malo prediciendo, pero servirá para dar una idea de los problemas que pueden tener los modelos de árbol previamente entrenados. Para ello realizamos el siguiente gráfico de partición:



En general se puede ver que el árbol realiza un buen trabajo con los valores bajos (esquina superior derecha del gráfico). Pero cuando intenta predecir el grupo formado al centro de la izquierda le es más costoso (no sólo porque no hay una clara separación de los datos) sino que también porque sería necesaria más profundidad para el árbol, lo que conduce a un posible sobreajuste.

Vecinos más cercanos (KNN)


Utilizaremos KNN con $K=1$ para realizar la predicción sobre R^2 , la predicción resultó con $\widehat{ECM}_{LOOCV} = 5,1068$ por lo que obviamente no es un buen modelo, pero creemos que será útil para ver aproximadamente cómo se comportan los modelos que usan KNN y quizás algunas dificultades.



Vemos aquí en este gráfico que la densidad de las observaciones no resulta uniforme, esto podría llevar a un posible problema a la hora de elegir tanto la medida de pesos (uniforme o por distancia) y, ligado a esto, a la hora de elegir la distancia, como también en la elección de K . Además, se pueden ver que algunas instancias azules se encuentran entremedio de múltiples instancias rojas, esto denota la posible falta de varianza en algunas direcciones. Sin embargo este gráfico nos muestra que en general las regiones están separadas, por lo que KNN podría realizar un buen trabajo con algún otro preprocesamiento de los datos y/o selección de variables.

Regresión no paramétrica

Veremos ahora el ajuste realizado mediante regresión no paramétrica para las primeras dos componentes principales. Primero se escalan ambas componentes mediante $MMScaler$, la regresión se realizó con una ventana de tamaño 0.06 y kernel gaussiano, la distancia elegida fue $L2$.




El $\widehat{ECM}_{LOOCV}$ dio 3,9848 por lo que no se trata de un buen modelo, pero sirve para ver alguna de las dificultades que puede tener la regresión no paramétrica, por ejemplo la diferencia de alturas para los puntos de mayor densidad dificulta la predicción en esa zona, así como también se pueden ver algunos puntos más atípicos que fuerzan la forma del ajuste

Selección de variables: Lasso

En los últimos dos preprocesamientos mostrados nos centramos en una reducción de dimensiones de los datos agrupando todos estos mediante transformaciones: por rangos de frecuencias y por componentes principales. En la presente sección comenzaremos el preprocesamiento con una selección de variables, utilizando Lasso. El hecho de que Lasso penalice la norma L1 para los $\hat{\beta}$ hace que muchas veces se descarten variables (es decir, estima los β como 0). Utilizando esta selección de variables, analizaremos todos los modelos ya propuestos.

En primer lugar, realizamos la selección de variables, buscando el λ óptimo para Lasso por K-Fold Cross Validation con $k = 5$, y obtuvimos estos resultados.



Utilizamos dos reglas distintas para elegir el λ óptimo.

- El λ que minimiza el error de Cross Validation.
Esto es, $\hat{\lambda}_{CV} = \operatorname{argmin}_{\lambda} CV(\lambda)$
- Utilizando la regla de un desvío estándar.
Es decir, $\hat{\lambda}_{1SD} = \max \left\{ \lambda : CV(\lambda) < CV(\hat{\lambda}_{CV}) + SD(\hat{\lambda}_{CV}) \right\}$.

En este último caso, al utilizar siempre un $\hat{\lambda}$ más grande, se deberían utilizar menos variables, generando así un modelo más simple. En otras palabras, sigue el principio de parsimonia.

Por otro lado, obtuvimos también que el mejor escalador era el MinMaxScaler (todos los datos con valores entre 0 y 1). Entrenamos los modelos con ambos $\hat{\lambda}$ obtenidos. A continuación visualizamos los $\hat{\beta}$ para cada uno de estos. Se indican en violeta las variables que fueron descartadas.




Figura 1: Selección con $\hat{\lambda}_{CV}$




Figura 2: Selección con regla de un desvío estándar

El primer modelo, al utilizar un $\hat{\lambda}$ menor, se queda con más variables (70), mientras que el segundo se queda con 15 variables menos (55).

Utilizando la selección filtrada por Lasso, entrenamos los modelos con cada regla de selección mencionada y obtuvimos los siguientes resultados.

Resumen

	Tipo	Preprocesamiento	$\widehat{ECM}$	R_{adj}^2	p
M14	LM	Lasso (min)	1,0458	0,8942	70
M15	Ridge	Lasso (min)	0,9144	0,9075	70
M16	ABR	Lasso (min)	1,4510	0,9101	10
M17	KNN	Lasso (min) + MMScaler	0,7941	0,9196	70
M18	RNP	Lasso (min) + MMScaler	0,7623	0,9229	70
M14(2)	LM	Lasso (1ds)	0,9744	0,9155	55
M15(2)	Ridge	Lasso (1ds)	0,9754	0,9154	55
M16(2)	ABR	Lasso (1ds)	1,4619	0,9063	12
M17(2)	KNN	Lasso (1ds) + MMScaler	0,8780	0,9239	55
M18(2)	RNP	Lasso (1ds) + MMScaler	0,8281	0,9282	55

Selección de variables: Stepwise Forward


Otros preprocesamientos estudiados en el curso fueron el StepWise Forward y el StepWise Backward. En éstos se busca elegir el conjunto de variables que maximiza el valor obtenido del estadístico F para las distintas regresiones lineales posibles. El StepWise Forward, empieza analizando todos los modelos más simples (con una sola variable) y se queda con la variable que optimiza el F-Score. De forma incremental, agregando una variable por iteración, genera un orden de importancia para las variables. En contraposición, el método Backward comienza con todas las variables y descarta a las mismas una por una.

Siendo que el set de datos contiene más variables que observaciones, la matriz de diseño está mal condicionada. Por lo tanto, el método backward no es posible de ejecutar. En esta sección realizaremos una selección de variables utilizando el método Forward, y evaluaremos todos los modelos ya propuestos.


En función de generar la selección, debimos elegir la cantidad de variables que buscamos filtrar. En este sentido, realizamos K-Fold Cross Validation sobre Step-Forward y elegimos la cantidad de variables que minimizaron el error cuadrático medio estimado. A continuación mostramos una visualización la cual muestra el $\widehat{ECM}$ con $k = 40$, en relación a la cantidad de variables utilizadas para entrenar un modelo lineal.

Cabe aclarar que probamos sólo hasta 155 variables elegidas pues con $k=40$ cada carpeta tendrá $160 - 160/40 = 156$ observaciones, con ello el máximo de variables estará acotado en 155 para así mantener a la cantidad de variables por debajo de la cantidad de observaciones.

Error según la cantidad de variables elegidas



En este gráfico podemos ver que en un principio (para pocas variables utilizadas) el error es muy alto, pero que rápidamente este error cayó hasta aproximadamente 1 y comenzó a subir hasta mantenerse constante a medida que más variables eran agregadas. En el gráfico se puede ver que el mínimo se alcanza en algún valor entre 10 y 30 variables utilizadas, por lo que analizaremos esa cantidad de variables con más detenimiento en otro gráfico, en el cual mostraremos ahora el $\widehat{ECM}$ por LOOCV (antes fue con K-fold(40))



Se observa en el gráfico que $\widehat{ECM}_{LOOCV}$ alcanza un mínimo cuando la cantidad de variables es 17. Como último paso aplicamos Step-Forward, esta vez con todo el set de entrenamiento, y nos quedamos para la presente selección de variables con las primeras 17 elegidas por el método, que fueron (por orden de selección):

- | | | | |
|-----------|-----------|-----------|-----------|
| (1) f158 | (2) f100 | (3) f169 | (4) f135 |
| (5) f225 | (6) f242 | (7) f342 | (8) f211 |
| (9) f292 | (10) f105 | (11) f173 | (12) f107 |
| (13) f241 | (14) f334 | (15) f232 | (16) f187 |

Queda entonces entrenar los modelos, mostraremos los resultados a continuación.

Resumen

	Tipo	Preprocesamiento	$\widehat{ECM}$	R^2_{adj}	p
M19	LM	StepForward	0,6901	0,9561	17
M20	Lasso	StepForward+StScaler	0,6863	0,9563	17
M21	ABR	StepForward	1,4791	0,9108	9
M22	KNN	StepForward+MMScaler	0,7031	0,9552	17
M23	RNP	StepForward	0,9138	0,9418	17

Análisis de resultados

En esta sección analizaremos los resultados obtenidos, para ello tomaremos dos posibles escenarios:

- **Escenario 1:** medir el espectro para las frecuencias entre 100 y 400 tiene un costo (en dinero) similar a medir algunas pocas frecuencias. Es decir, realizar la medición para algunas pocas frecuencias es igual de costoso que medir todas y ya. Esto nos da pie a pensar que los modelos que utilizan todas las variables son útiles (y por ende sólo interesa el error obtenido).

- **Escenario 2:** el costo de medir el espectro crece linealmente con la cantidad de frecuencias a medir del espectro. Es decir, realizar la medición para algunas pocas frecuencias resulta más barato que medir todas. Esto nos indica que también es necesario elegir el modelo según la cantidad de variables utilizados (y por ende utilizaremos el R_{adj}^2).

Escenario 1


Si suponemos que el costo de medir todas las frecuencias se asemeja al costo de medir algunas pocas, debemos darle menor importancia a las métricas que penalizan la complejidad del modelo en razón de la cantidad de variables (R_{adj}^2), y mayor importancia a las que penalizan la distancia del valor ajustado al valor verdadero (ECM).

Elección del modelo

Luego de revisar todos los modelos entrenados a lo largo del trabajo práctico decidimos escoger al modelo $M7$, que es un KNN entrenado mediante el preprocesamiento que agrupa las frecuencias y luego escalado mediante MMScaler. Elegimos este modelo porque presentó el menor $\widehat{ECM}$ de todos, con un valor de 0,5966.


Es hora de ver cómo se comportó el modelo frente a holdout y tomar la decisión final u observaciones finales del mismo. Para ello haremos dos gráficos, uno mostrando el error cuadrático medio y otro mostrando el error relativo de la predicción.

Error cuadrático



Podemos observar que el error cuadrático parece haber aumentado para Holdout respecto al esperado según LOOCV, de hecho este fue de $\widehat{ECM}_{HOLDOUT} = 0,9243$. Algunas observaciones parecen haber tenido una predicción muy lejana a su valor original (como podrían ser la 27 o la 107, incluso la 122 o 154) frente a otras que obtuvieron errores esperados. Esto deja al modelo en una posición de inestabilidad, pues algunos valores parecen ser predichos excelentemente mientras que otros muy mal. Sin embargo, creemos que sólo mirar este gráfico perjudica nuestro entendimiento sobre el modelo, para ello observaremos el comportamiento de los errores relativos, quienes también tienen en cuenta la magnitud en dos aspectos (el valor de Y a predecir, como también su unidad).

Error relativo



De este gráfico podemos notar que el modelo es infructuoso para valores de Y pequeños (por ejemplo para Y menor a 8) pues sus errores relativos superan con creces más del 15 %. Esto tendrá que tenerse en cuenta a la hora de utilizarlo para estos tipos de vasijas (enumeradas en el gráfico). Sin embargo, incluso en el entrenamiento se obtuvieron algunos resultados parecidos, por lo que creemos que la performance en holdout se asemeja a la performance en entrenamiento, es decir, es representativo.


Escenario 2

Si suponemos que el costo de medir algunas frecuencias es mucho menor que el costo de medir todas, debemos darle mayor importancia a las métricas que penalizan la complejidad del modelo en razón de la cantidad de variables (en este caso R_{adj}^2).

Elección del modelo

Analizando los modelos entrenados, recomendamos el uso del modelo M_{20} , se trata de una regresión lineal regularizada con Lasso, cuyo previo preprocesamiento fue StepForward y StScaler. Este modelo obtuvo un error cuadrático medio por validación cruzada de 0,6863, pero lo más importante es que sólo utiliza 17 variables. Estas 17 variables son las enumeradas en la sección donde se entrenó el modelo. Veamos cómo se comportó el modelo frente a los datos guardados en holdout:


Error cuadrático



Podemos observar que el error cuadrático en Holdout parece estar bien respecto al esperado según LOOCV, el valor es $\widehat{ECM}_{HOLDOUT} = 0,8224$, por lo que efectivamente vemos que el error parece mantenerse en un valor esperado. Además, este valor es relativamente común (respecto a lo obtenido en todos los modelos del trabajo) por lo que, creemos que el modelo no tuvo problemas de sobreajuste.

Veamos ahora el error relativo.

Error relativo



De forma similar al modelo previo se puede observar que este modelo tiene problemas con los valores de Y pequeños. Es decir, nuevamente esto debería tenerse en cuenta a la hora de utilizar el modelo, pues predecir la cantidad de óxido de sodio presente en la vasija con precisión resulta imposible si esta presenta poco. Por lo demás, vemos que el modelo ejecuta correctamente la predicción (para el error relativo) para valores de Y grandes, pues casi todas las instancias se encuentran en un error relativo menor al 10 % que, si bien no es increíble, podría llegar a ser de

utilidad.

Posibles mejoras

En esta sección propondremos posibles mejoras y enumeraremos algunas falencias que presenta nuestro trabajo práctico, las cuales por falta de tiempo y/o alcance no fueron implementadas.

Errores

Un problema común que presentaron nuestros modelos es la falta de noción de magnitudes en el error. Es decir, los modelos al entrenarse no tienen en cuenta la magnitud de la variable a predecir, llevando a los modelos a entrenarse únicamente mediante error cuadrático medio, provocando así que cuando sea necesario predecir una instancia cuya variable objetivo es pequeña el error relativo se dispare a valores de 40 % o incluso 60 %, valores completamente ilógicos si se piensa en un modelo cuyo objetivo sea precisión y no exactitud.

Es por eso que pensamos que una posible solución a este problema es realizar la búsqueda de hiperparámetros teniendo en cuenta además el error relativo de la predicción, así nos ahorramos el problema de sólo tener en cuenta el error cuadrático medio y tener múltiples opciones cuando entrenamos los modelos.

Por último el hecho de que utilizemos pocas observaciones para calcular el error cuadrático medio estimado hace que este no sea tan significativo (como para, por ejemplo, realizar intervalos de confianza y el análisis de supuestos). Una posible mejora hubiese sido "generar" nuevas muestras mediante la técnica de bootstrapping.

Transformación

Otra falencia presentada en el trabajo práctico es la falta de pruebas con la transformación de los datos, con el objetivo de obtener así una mejor distribución de los mismos antes de entrenar los modelos. Esto acarrea además algunos problemas como el anteriormente mencionado. En parte el problema de los errores relativos es la distribución de la variable objetivo, pues el rango de Y es aproximadamente $(0,5; 18)$. Al optimizarse el error cuadrático medio se penaliza de igual modo predecir $\widehat{Y}_0 = 19$ cuando el valor verdadero es $Y_0 = 18$, y predecir $\widehat{Y}_1 = 2$ cuando el valor verdadero es $Y_1 = 1$.

Probablemente con algún tipo de transformación se obtendría una variable objetivo más sencilla de tratar tanto para los errores como también para las correlaciones con las variables predictoras. Estas últimas también tuvieron nulo trato de transformación, salvo normalizaciones y redimensiones lineales (MMScaler) no se probó con ningún otro tipo de transformación, como podrían llegar a ser polinomios, logaritmos, raíces, etc.

A modo de ejemplificación, si hubiéramos tomado la transformación para la variable objetivo $T(y) = \log(y + 1)$, se penalizaría mucho más predecir $\widehat{Y}_1 = 2$, cuando $Y_1 = 1$, que estimar $\widehat{Y}_0 = 19$ cuando $Y_0 = 18$. Esto es así, porque $T(\widehat{Y}_1) - T(Y_1) = 0,477 - 0,301 = 0,176$ y $T(\widehat{Y}_0) - T(Y_0) = 1,301 - 1,279 = 0,022$.

Estas transformaciones podrían haberse decidido mediante el gráfico de correlaciones presentado en el análisis exploratorio del trabajo práctico, pues encontrar la o las transformaciones que maximizan la correlación con la variable objetivo, así como reducen la correlación mutua entre variables predictoras podría haber significado un gran avance en la dirección de la descorrelación y la selección de variables, así como también, en el entrenamiento y selección de modelos.

Intervalos de predicción

Algo que sufre nuestro trabajo práctico es la falta de intervalos de predicción de la variable objetivo, esto deja a nuestros modelos únicamente con el valor predicho pero sin ningún tipo de intervalo (necesario a la hora de realizar un trabajo profesional)

Si bien se realizó un intento por hacer notar una posible cota de error mediante los gráficos de errores relativos según los valores esperados, creemos que resulta incompleto.

Esquema de trabajo

Un problema recurrente en el proceso de entrenamiento de los modelos, el cual no fue relatado en el informe, es el alto grado de sobreajuste en algunos intentos de entrenamiento. Sobre todo a la hora de la elección de variables, pues, cuando se seleccionan variables mediante todo los datos de

entrenamiento y se procede a calcular el error cuadrático medio (por validación cruzada o cualquier otra técnica) sobre esos mismos datos de entrenamiento, se produce lo que se conoce como Fuga (Leak en inglés) de información o sesgo en la estimación del error en entrenamiento, pues tanto la elección de variables como la búsqueda de hiperparámetros, se realizó con los mismos datos que luego se utilizarán para estimar el error por LOOCV o validación cruzada.

Como solución a este problema creemos que sería necesario haber realizado una mejor separación de los datos, esta sería:

- **Train:** los datos que se utilizan para seleccionar variables y buscar hiperparámetros mediante validación cruzada y minimización del error.
- **Test:** los datos que se utilizan para calcular la estimación del error insesgado a cualquier tipo de sesgo o fuga de información.
- **Holdout:** los datos que se utilizan con el único fin de confirmar que los modelos no sobreajustaron (no utilizada sino hasta la finalización del trabajo práctico, como se hizo en el presente).

Esta separación nos permitiría ahorrarnos los problemas que tuvimos a la hora de entrenar modelos y elegirlos mediante una estimación que resultó (a veces sí y a veces no) sesgada.

Sin embargo queremos notar que en principio tuvimos en cuenta este esquema, pero dada la poca cantidad de observaciones, y todos los problemas que surgen al tener $n < p$, no queríamos dejar más observaciones afuera del entrenamiento. Por lo que decidimos ir por el esquema que utilizamos en el trabajo, pero conscientes de que esto podría llegar a ocurrir.

Presentación

Casi todos los modelos fueron entrenados utilizando R y otros pocos utilizando Python (KNN). Todos los entrenamientos y cálculos omitidos en el presente informe, se encuentran en un repositorio de github, cuyo link es el siguiente <https://github.com/Lukas-De-Angelis-Riva/Aprendizaje-estadistico>.

Creemos que estos notebooks no tienen el nivel de orden y prolijidad necesarios para ser parte de la entrega, como también creemos que podrían sumar en la entrega, es por ello que una posible mejora del trabajo práctico podría ser un repositorio y notebooks más prolijos y ordenados.

Anexo

Análisis de supuestos


En esta sección abordaremos los análisis de supuestos necesarios para los modelos, en particular nos centraremos en las regresiones lineales, pues para árbol de regresión y KNN no es necesario ningún supuesto, y los demás (PCA y Regresión no paramétrica) fueron abordados tanto en el análisis exploratorio como en su respectiva introducción.

Para comprobar los supuestos de la regresión lineal realizaremos:


- Un gráfico con los p-valores de los coeficientes obtenidos.
- Un gráfico para comprobar la distribución de los errores según el valor ajustado.
- Un gráfico cuantil-cuantil de los residuos para analizar si se trata de una distribución t-student.

Modelo 9


El modelo 9 es la regresión lineal entrenada con las primeras 6 componentes principales. Mostramos las visualizaciones mencionadas.



En el presente gráfico observamos que todas las componentes principales tienen una significación alta para la regresión lineal, esto es, es muy improbable que los $\hat{\beta}$ sean nulos.





El promedio de los residuos estudentizados t_i es muy cercano a cero. Además, no pareciera haber una relación de dependencia entre los residuos y los valores ajustados. Por lo que el supuesto de homocedasticidad podría cumplirse.




Por último, los residuos parecieran efectivamente distribuirse aproximadamente como una t de student ya que presentan el fenómeno de colas pesadas. Luego, no se puede descartar que el modelo cumpla con los supuestos requeridos para la regresión, por lo que, supondremos que se cumplen.

Modelo 9(2)

Este modelo utiliza únicamente las primeras dos componentes principales. Mostramos a continuación los gráficos correspondientes al mismo.




Podemos ver en este gráfico que existe una relación entre los valores ajustados y los residuos (que, recordamos se calculan como $r_i = y_i - \hat{y}_i$) los cuales para valores cercanos a un valor ajustado de 5 no superan el cero. Esto nos indica que, para estos valores, la predicción está sobreestimada. Por lo que, rechazamos que se cumpla el supuesto de homocedasticidad, pues el presente gráfico no se comporta como una nube de puntos.




En cuanto al gráfico cuantil-cuantil, no se puede afirmar que no se corresponde con una t de student, al tener colas pesadas. De todas formas y como ya se ha dicho antes, rechazamos el cumplimiento de homocedasticidad y, por ende, también desestimamos el modelo.


Modelo 14



Es preocupante la situación observada en este gráfico, pues vemos que más de la mitad de los coeficientes no llegan a rechazar el test. Podemos ver además que las barras de error tocan al cero en todos estos casos, esto nos indica que la regresión podría (o no) tener problemas con el supuesto de “debe existir una relación lineal”, porque, como vemos, los coeficientes no parecen significativos. De todas formas aún quedan ver los otros dos gráficos antes de tomar una decisión.



Este gráfico parece ser correcto pues los errores se distribuyen como una nube de puntos alrededor del cero.




Vemos en este gráfico que definitivamente no corresponde a una distribución t de student, pues los cuantiles de la normal se alcanzan antes que los cuantiles de la distribución (cosa que debería ser al revés en caso de que los residuos se distribuyeran como una t de student) Por lo que rechazamos el supuesto de normalidad del error y con él al modelo.


Modelo 14(2)


El análisis correspondiente a este modelo es similar al análisis hecho para el anterior.

Valores de los coeficientes estimados de la regresión



Valores de los coeficientes estimados de la regresión







Vemos que el modelo se comporta similar al anteriormente analizado y las conclusiones son las mismas, se rechaza debido al supuesto de la normalidad del error.

Modelo 19


Este modelo pertenece a la familia de los entrenados luego de haberse realizado la selección de variables mediante el método de Forward. Veamos los gráficos.



Vemos que la mayoría de los coeficientes rechazan el test, y los que no, es por poco (ver las barras de error). Por lo que en este sentido el modelo funciona correctamente.



Viendo el gráfico se puede decir que los residuos se distribuyen como una nube de puntos alrededor del cero.



Nuevamente, las colas de la distribución de los residuos son livianas, a diferencia de lo esperado. De todas formas en esta ocasión las colas se acercan más a la recta. Por lo que, si bien no se trata de una t-student, el modelo no parece diferir tanto.